

## PCA 降维

华南师范大学 数学科学学院 朱致鹏

前面我们说过 MDS 通过线性变换来进行有效降维, 若要求低维子空间对样本具有最大可分性, 则得到一种极为常用得线性降维方法——PCA

PCA 算法本质就是找一些投影方向, 使得数据在这些投影方向上的方差最大, 而且这些投影方向是相互正交的。这其实就是找新的正交基的过程, 计算原始数据在这些正交基上投影的方差, 方差越大, 就说明在对应正交基上包含了更多的信息量。原始数据协方差矩阵的特征值越大, 对应的方差越大, 在对应的特征向量上投影的信息量就越大。反之, 如果特征值较小, 则说明数据在这些特征向量上投影的信息量很小, 可以将小特征值对应方向的数据删除, 从而达到了降维的目的。

对于正交属性空间中得样本点, 如何让用一个超平面对所有样本进行恰当得表达?

这样的超平面由下面两个性质:

- ①最大可分性: 样本点在这个超平面上的投影能尽可能分开
- ②最近重构性: 样本点到这个超平面得距离都足够近
- ①首先针对最大可分性, 它要使投影后的样本点的方差最大化!!!

假设原始数据  $\{x_1, x_2, x_3, \dots, x_n\}$ , 先对样本点中心化 (归一化) 可使得特征均值等于 0

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

中心化后  $\{z_1, z_2, z_3, \dots, z_n\} = \{x_1 - \mu, x_2 - \mu, \dots, x_n - \mu\}$ , 向量  $z_i$  在  $w$  (超平面) 上

的投影为  $w^T z_i$ 。方差  $D(z) = \frac{1}{n} \sum_{i=1}^n (w^T z_i)^T (w^T z_i) = w^T \left( \frac{1}{n} \sum_{i=1}^n z_i z_i^T \right) w$ , 其中  $z$  的方差

为  $tr\left(\frac{1}{n} \sum_{i=1}^n z_i z_i^T\right)$

要令方差尽可能大, 即求解最优化问题 (含等式约束), 用拉格朗日乘数法, 接下来先介绍求解方法:

(一) 无约束

$$\text{形如: } \min f(x) = x^2 - 2x + 1$$

方法: 高中所学求导求极值

(二) 有约束

1. 等式约束

$$\min f(x)$$


$$\{h_i(x) = 0 \quad i = 1, 2, \dots, n\}$$

从几何角度看, 该问题的目标是在方程  $h(x) = 0$  确定的  $d-1$  维曲面上寻找能

使目标函数  $f(x)$  最小化的点。此时不难得到如下结论：

①对于约束曲线上的任意点  $x$ ，该点的梯度  $\nabla h(x)$  正交于约束曲线

这点很容易理解，因为梯度是下降最快的方向，显然该点曲面正交，下图可以帮助理解：



②在最优点  $x^*$ ，目标函数在该点的梯度  $\nabla f(x^*)$  正交于约束曲线

可以用反证法解释：如果  $\nabla f(x^*)$  不正交于约束曲线，那么在约束曲面上，我们总可以沿着  $\nabla f(x^*)$  的相反方向移动，使  $f(x)$  函数值更进一步下降，因为梯度的反方向就是函数值下降最快的方向，所以如果找到了最优点  $x^*$ ，则该点梯度  $\nabla f(x^*)$  必定正交于约束曲线，使我们无法在约束曲面上沿着梯度的负方向移动，就像图中的交点。

由此可知，在最优点  $x^*$ ，梯度  $\nabla h(x)$  和  $\nabla f(x)$  的方向必定相同或相反，即存在  $\lambda \neq 0$  使得

$$\lambda \nabla h(x^*) + \nabla f(x^*) = 0 \quad (8)$$

$\lambda$  称为拉格朗日乘子。定义拉格朗日函数

$$L(x, \lambda) = f(x) + \lambda h(x) \quad (9)$$

可以发现，对 (9) 求  $x$  的偏导数其实就是 (8)，对 (9) 求  $\lambda$  得偏导数即得到约束条件  $h(x) = 0$ 。于是，原约束优化问题可以转化为对拉格朗日函数得无约束优化问题。

## 2. 不等式约束

$$\begin{aligned} \min \quad & f(x) \\ \{h_i(x) \leq 0 \quad & i=1, 2, \dots, n \end{aligned}$$

这种情况得最优点  $x^*$  或在  $h(x)=0$  边界上，或在  $h(x)<0$  的区域中，对于  $h(x)<0$  的情形，约束  $h(x)\leq 0$  将不起作用，可直接通过条件  $\nabla f(x)=0$  来获得最优点；这等价于将  $\lambda$  置零后对拉格朗日函数求  $x$  的偏导数置零得到最优点。那  $h(x)=0$  的时候类似于等式约束，需要注意的是，梯度  $\nabla h(x)$  和  $\nabla f(x)$  的方向必定相反，即存在常数  $\lambda>0$  使得  $\lambda\nabla h(x^*)+\nabla f(x^*)=0$ 。结合两种情况，必满足  $\lambda h(x)=0$ ，此时的约束变成如下：

$$\begin{cases} h(x) \leq 0 \\ \lambda \geq 0 \\ \lambda h(x) = 0 \end{cases} \quad (10)$$

称为 KKT 条件。

### 3. 多约束

推广到多约束：

$$\begin{aligned} \min \quad & f(x) \\ \begin{cases} h_i(x) \leq 0 & i=1,2,\dots,n \\ g_j(x) = 0 & j=1,2,\dots,m \end{cases} \end{aligned}$$

此时拉格朗日函数为：

$$L(x, \lambda, \mu) = f(x) + \mu_i \sum_{i=1}^n h_i(x) + \lambda_j \sum_{j=1}^m g_j(x) \quad (11)$$

KKT 条件：

$$\begin{cases} h_i(x) \leq 0 \\ \mu_i \geq 0 \\ \mu_i h_i(x) = 0 \end{cases} \quad (12)$$

回到求解方差问题上，我们要求解最优化问题：

$$\begin{cases} \max \quad \text{tr}(W^T Z Z^T W) \\ \text{s.t.} \quad W^T W = I \end{cases}$$

建立拉格朗日函数：

$$L(w, \lambda) = \text{tr}(W^T Z Z^T W) + \lambda(W^T W - I)$$

对  $w$  偏导置零：

$$\nabla_w L(w, \lambda) = 2(Z Z^T)W + 2\lambda W = 0$$

得到：

$$Z^T Z W = \lambda W$$

代入原问题：

$$\text{tr}(W^T Z Z^T W) = \text{tr}(W^T \lambda W) = \lambda$$

即要求  $Z^T Z$  的特征值及对应的特征向量构成的  $W$ 。

②最近重构性（最小平方误差）

样本点到超平面的距离：

$$\text{dist}(x, D) = \|x_k - \hat{x}_k\|_2$$

其中， $\hat{x}_k$  是  $x_k$  在超平面  $D$  上的投影向量： $\hat{x}_k = \sum_{j=1}^d (w_j^T x_k) w_j = \sum_{j=1}^d z_j w_j$ 。

（ $w_j^T x_k$  是  $x_k$  在  $w_j$  方向上投影的长度）

要令  $\text{dist}(x, D)$  最小，即求解如下问题：

$$\begin{cases} \min & \sum_{k=1}^n \|x_k - \hat{x}_k\|_2^2 \\ \text{s.t.} & w_j^T w_i = \begin{cases} 1, i=j \\ 0, i \neq j \end{cases} \end{cases}$$

$$\begin{aligned} \|x_k - \hat{x}_k\|_2^2 &= (x_k - \hat{x}_k)^T (x_k - \hat{x}_k) = x_k^T x_k - x_k^T \hat{x}_k - \hat{x}_k^T x_k + \hat{x}_k^T \hat{x}_k \\ &= x_k^T x_k - 2x_k^T \hat{x}_k + \hat{x}_k^T \hat{x}_k = x_k^T x_k - \sum_{j=1}^d w_j^T x_k x_k^T w_j \end{aligned}$$

那么

$$\min \sum_{k=1}^n \|x_k - \hat{x}_k\|_2^2 = \sum_{k=1}^n (-\text{tr}(W^T x_k x_k^T W) + x_k^T x_k)$$

那么，原问题转化为：

$$\begin{cases} \min & -\text{tr}(W^T X X^T W) \\ \text{s.t.} & W^T W = I \end{cases}$$

与①一致。